

Análisis de Datos y Aprendizaje Automático

Proyecto Integrador

Autor: Alejandro Rodríguez

Contendio

- Introducción
- Metodología
- Resultados y hallazgos
- Conclusiones

Introducción

Contexto del problema

- El flujo de pacientes con afecciones cardiacas en el Hospital anualmente es elevado y todos los datos son recogidos por expertos en el área clinica y cardiología.
- Como resultado de las consultas se realizan análisis de varios parámetros médicos que son necesarios para un diagnóstico final.
- Analizar los datos que son recogidos por todos los especialistas no es tarea fácil por lo que es necesario un mecanismo que ayude a la toma de decisiones.

Contexto del problema

- ¿Es posible predecir una falla cardiaca con las variables que contamos? ¿Es necesario emplear las variables menos importantes en el análisis?
- ¿Los análisis de laboratorio que se realizan a los pacientes aportan valor a la posibilidad de predecir una falla cardiaca?
- ¿Los pacientes que ingresan con un IMA (infarto) tienen mayor probabilidad de fallecer?
- ¿Cuál es la edad promedio de un paciente que fallece de una enfermedad cardiaca?

Objetivo General

- Predecir la probabilidad de que el paciente padezca una falla cardiaca que pueda llevar a su fallecimiento.

Objetivo Específico

- Predecir el diagnóstico del egreso del paciente.

Metodología

Fuentes de datos

- La base de datos fue obtenida por solicitud de un especialista de cardiología para realizar una investigación para optar por el grado Científico de Master en Ciencias Médicas.
- Los datos se obtienen de los pacientes que llegan a la sala de coronario del hospital con el objetivo de tener un registro de todos los análisis que se le realizan y las posibles afecciones cardiacas.
- El dataset cuenta con varios campos que no están permitidos su divulgación, por lo que como primera parte del procesamiento, se eliminaron varias columnas.

Preprocesamiento de datos


- En primera instancia los datos fueron cargados correctamente con pandas, y según la información del DataFrame habían **1370** filas con **62** columnas (variables).
- Del total de variables, **47** son del tipo float64 y **15** del tipo object. La memoria total a utilizar fue de **706.6 KB**.
- Del dataframe se eliminaron las columnas Nombre, Apellidos, Numero de Historia Clínica, Fecha de Ingreso y Egreso, el tiempo de Estadía y Descripción.

Preprocesamiento de datos

- Se analizó el DataFrame y existen campos con valores vacíos (No NaN y No None) con un caracter "Espacio" y "-", que se sustituyeron por None para que las variables puedan ser interpretadas correctamente.
- Se creó un nuevo DataFrame con la selección de 24 variables que se consideraron importantes para cumplir el objetivo general.

Preprocesamiento de datos

- Se realizó el análisis de datos faltantes utilizando la librería missingno. Siguen un patrón **MNAR**.



Preprocesamiento de datos



- Los datos faltantes se imputaron eliminando todas las filas que presentaban valores faltantes. Por ser una base de datos médicos no se empleó un mecanismo de rellenado de datos.
- La variable **Creat** tenía un **43.8 porcentaje** de valores faltantes por lo que fue eliminada del análisis.
- Después realizar la limpieza de los datos faltantes el DataFrame quedó con **1022** registros y **23** variables.

Técnicas de análisis

- En el resumen descriptivo de las variables se detallaron 7 variables cuantitativas y 16 variables categóricas. Todas están devidamente codificadas.
- De acuerdo al objetivo específico, la variable objetivo **D egreso** (Categórica) contiene las clases que se deben de predecir.
- Para predecir esta variable se empleó un clasificador basado en árboles de decisión, como modelo de aprendizaje supervisado.


Técnicas de análisis

- En el análisis univariado de las variables cualitativas se realizó la detección de valores atípicos empleando el método Z-Score.
- Se realizó la normalización de las variables empleando el método **RobustScaler** ya que es robusto ante la presencia de valores atípicos.




Técnicas de análisis

- En el análisis univariado de las variables categóricas se observa que todas presentan desbalance.
- Las variables que registran las complicaciones tiene mayor peso en pacientes no complicados.




Técnicas de análisis

- Se realizó un análisis de correlación empleando el método de Pearson y se representó con la matriz de correlación.
- La variable objetivo no presenta una correlación fuerte con las variables predictoras.




Técnicas de análisis

- La variable objetivo **D egreso**, es multiclase y está desbalanceada.
- Se construyó y evaluó el modelo teniendo en cuenta que es una variable multiclase.




Resultados y hallazgos

Visualizaciones



- Al analizar la variable objetivo respecto a las características cuantitativas no se observó una realación fuerte.

Visualizaciones




- Al analizar la variable objetivo respecto a las características categóricas se observaron relaciones fuertes con variables asociadas a las complicaciones.

Visualizaciones

- Se realizó la división de datos de la forma 70% para el entrenamiento y un 30% para la validación.
- Se entrenó un modelo de **DecisionTreeClassifier** y se realizaron predicciones sobre el conjunto de prueba.

÷	proba_0	÷	proba_1	÷	categoria	÷
0	0.0		0.0		5.0	
1	0.0		0.0		5.0	
2	0.0		0.0		5.0	
3	1.0		0.0		1.0	
4	1.0		0.0		1.0	
5	0.0		0.0		10.0	
6	0.0		0.0		5.0	
7	0.0		0.0		5.0	
8	0.0		0.0		5.0	
9	1.0		0.0		1.0	
10	0.0		0.0		5.0	
11	0.0		0.0		12.0	
12	1.0		0.0		1.0	
13	0.0		0.0		3.0	
14	0.0		0.0		9.0	

Visualizaciones



Interpretación de resultados

- Las características **Diag ing**, **ECG ing**, **Edad** y las que tienen que ver con **Complicaciones** son de relevancia a la hora de predecir el **Diagnóstico al egreso**.
- Se analizó la evaluación del rendimiento del modelo y se visualizó el árbol resultante.
- El accuracy del modelo es de **0.84** y en las pruebas realizadas se observó que no predice todos los valores a una misma clase, aunque la variable objetivo esté desbalanceada.
- Se analizaron otras métricas para evaluar el resultado.


Validación de resultados

- Se realizó la evaluación del modelo a través de la matriz de confusión y el reporte de clasificación.
- El modelo predice correctamente el **92% de IMA**, el **65% de Otros**, el **89% de AIA**, el **92% de Trastornos**, el **75% de I Cardíaca** y el **70% de Pericarditis**.

	precision	recall	f1-score	support
IMA	0.92	0.91	0.91	107
IMA no Q.	0.00	0.00	0.00	1
Otros.	0.65	0.62	0.63	21
Miocardio patía.	0.00	0.00	0.00	1
AIA.	0.89	0.88	0.88	113
Síncope.	0.00	0.00	0.00	2
TEP.	0.00	0.00	0.00	1
Dolor Torácico	0.00	0.00	0.00	0
Trastornos	0.92	0.83	0.87	29
I Cardíaca.	0.75	0.88	0.81	24
Pericarditis.	0.50	0.50	0.50	2
accuracy			0.85	301
macro avg	0.42	0.42	0.42	301
weighted avg	0.86	0.85	0.85	301


Matriz de confusión de árbol de decisión

Valores Actuales o Reales	IMA	IMA no Q.	Otros.	Miocardio patía.	AIA.	Síncope.	TEP.	Dolor Torácico	Trastornos	I Cardíaca.	Pericarditis.
IMA	97	0	2	0	7	0	0	0	0	0	1
IMA no Q.	1	0	0	0	0	0	0	0	0	0	0
Otros.	1	0	13	0	4	0	2	0	0	1	0
Miocardio patía.	0	0	0	0	1	0	0	0	0	0	0
AIA.	5	1	0	0	99	0	0	2	0	6	0
Síncope.	0	0	1	0	0	0	0	0	1	0	0
TEP.	1	0	0	0	0	0	0	0	0	0	0
Dolor Torácico	0	0	0	0	0	0	0	0	0	0	0
Trastornos	1	0	1	0	0	3	0	0	24	0	0
I Cardíaca.	0	0	2	0	0	0	0	0	1	21	0
Pericarditis.	0	0	1	0	0	0	0	0	0	0	1
Valores Predichos	IMA	IMA no Q.	Otros.	Miocardio patía.	AIA.	Síncope.	TEP.	Dolor Torácico	Trastornos	I Cardíaca.	Pericarditis.



Validación de resultados

- Se analizaron las métricas AUC-ROC y Cross-validation – K-Fold, a través del método **StratifiedKFold** que es una métrica robusta para problemas multiclases



```
Fold 1: Accuracy = 0.8159, F1-macro = 0.4139
Fold 2: Accuracy = 0.8050, F1-macro = 0.4174
Fold 3: Accuracy = 0.8100, F1-macro = 0.3767
Fold 4: Accuracy = 0.7900, F1-macro = 0.4602
Fold 5: Accuracy = 0.8000, F1-macro = 0.4079
```

RESUMEN K-FOLD CROSS VALIDATION

```
Accuracy: 0.8042 (+/- 0.0198)
Precision: 0.4148 (+/- 0.0623)
Recall: 0.4223 (+/- 0.0665)
F1-Score: 0.4152 (+/- 0.0597)
```

Validación de resultados

- En las métricas analizadas, el accuracy es de **0.8042**, quiere decir que el modelo **acierta** en el **80%** de los casos, la **precisión promedio** es de **0.4148**, por lo que el **41%** de los diagnósticos del egreso son reales y el **recall** es de **0.4223** como promedio, por lo que el modelo detecta correctamente el **42%** de los diagnósticos del egreso.

Conclusiones

Conclusiones clave

- Con el modelo planteado se cumplió de forma parcial el objetivo general, ya que la variable objetivo **D egreso** al estar desbalanceada no mostró un desempeño aceptable para todas las clases, por lo que se debe buscar obtener más datos para balancear la variable.
- La base de datos, al ser de datos médicos y trabajar sobre la base de diagnósticos de pacientes se hace complejo lograr que la variable objetivo esté balanceada, pero se puede mitigar obteniendo más datos que hasta el momento solo se disponen de 1001 registros válidos.
- El modelo tiene dificultades en clasificar correctamente y tiene un alto número de falsos positivos.

Próximos pasos

- Aplicar si es posible algún modelo de aprendizaje no supervisado.
- Aplicar en tiempo real la predicción del modelo en el Hospital.
- Continuar entrenando y evaluando el desempeño del modelo con la entrada de nuevos datos.

Análisis de Datos y Aprendizaje Automático

Proyecto Integrador

Autor: Alejandro Rodríguez